Содержание

Введение 5

1. Подготовительный этап 7
   1.1. Формальная постановка задачи 7
   1.2. Анализ методов классификации 9
   1.3. Математические основы градиентного бустинга 10
      1.3.1. Решающее дерево как базовая модель 10
      1.3.2. Бустинг как градиентный спуск в пространстве функций . . . 10
      1.3.3. Логистическая функция потерь и ее производные 11
      1.3.4. Ньютоновский шаг: значения листьев и критерий разбиения . 11
      1.3.5. Инициализация ансамбля 13
      1.3.6. Гистограммная аппроксимация поиска разбиений 13
      1.3.7. Регуляризация: темп обучения и ранняя остановка 14
      1.3.8. Учет дисбаланса классов 14
   1.4. Обзор программных реализаций 14

2. Ориентировочный этап 16
   2.1. Описание и предобработка данных 16
   2.2. Признаковое описание семестра 18
   2.3. Метрики качества и базовые модели 19

3. Основной этап 22
   3.1. Условия проведения эксперимента 22
   3.2. Сравнительный анализ с базовыми моделями 23
   3.3. Анализ модели: подгруппы, порог, значимость признаков 25

Заключение 31

Список использованных источников 32

Введение

Государственная академическая стипендия назначается по итогам промежуточной аттестации, поэтому ее сохранение напрямую зависит от результатов ближайшей сессии. Возможность заранее, по данным уже закрытого семестра, выявлять обучающихся с повышенным риском потери права на стипендию позволяет своевременно принимать адресные меры поддержки. Этим определяется актуальность темы настоящей работы.

Цель работы – построение и исследование модели прогнозирования успеваемости обучающихся на основе данных промежуточной аттестации, оценивающей риск потери права на академическую стипендию по итогам следующего семестра.

Для достижения цели поставлены следующие задачи: 1) формализовать задачу прогнозирования как задачу бинарной классификации пар последовательных семестров и обосновать выбор математического аппарата; 2) выполнить аудит и предобработку данных зачетно-экзаменационных ведомостей и построить признаковое описание семестра; 3) обучить модель градиентного бустинга, сравнить ее с базовыми правилами, исследовать рабочую точку и значимость признаков; 4) подготовить отчет о прохождении практики в LaTeX.

Объект исследования – академическая успеваемость обучающихся, отраженная в зачетно-экзаменационных ведомостях. Предмет исследования – методы машинного обучения для прогнозирования результата следующего семестра по данным текущего.

Методологическую основу работы составляют аппарат градиентного бустинга над решающими деревьями в реализации `HistGradientBoostingClassifier` библиотеки scikit-learn, стандартные метрики качества бинарной классификации и перестановочный метод оценки значимости признаков; вычисления выполнены на языке Python.

Отчет состоит из введения, трех разделов, соответствующих этапам практики, заключения и списка использованных источников. В первом разделе дается формальная постановка задачи и излагаются математические основы используемого метода; во втором описываются исходные данные, их предобработка и признаковое описание, а также вводятся метрики качества и базовые модели сравнения; в третьем приводятся результаты обучения модели, сравнение с базовыми правила-

ми, анализ рабочей точки и значимости признаков; в заключении сформулированы итоги работы.

1. Подготовительный этап

Целью подготовительного этапа является формирование математической базы, необходимой для корректной постановки и решения задачи прогнозирования академических результатов студентов. На данном этапе выполняется формализация прикладной задачи как задачи бинарной классификации, проводится сравнительный анализ семейств моделей машинного обучения, подробно излагается математический аппарат выбранного метода – градиентного бустинга над решающими деревьями в гистограммной реализации, – а также выполняется обзор доступных программных реализаций.

1.1. Формальная постановка задачи

Тема научно-исследовательской работы – «Прогнозирование успеваемости на основе промежуточной аттестации обучающихся». Под *успеваемостью* далее понимается академический статус студента по итогам семестра (стипендиальный или нестипендиальный семестр в смысле определения ниже), под *промежуточной аттестацией* – результаты семестровых ведомостей (экзамены, зачеты, зачеты с оценкой, курсовые работы и проекты, аттестационные испытания ГИА). Прогнозируемой величиной является статус следующего семестра. Признаки строятся исключительно по промежуточной аттестации: баллы текущего контроля (первая-третья аттестации), присутствующие в исходных данных, в признаковое описание сознательно не включаются.

Предметная область устроена следующим образом. По действующим правилам назначения государственной академической стипендии результаты сессии семестра N полностью определяют выплату стипендии в семестре $N{+}1$: стипендию получает студент, закрывший семестр без оценок «удовлетворительно», без неудовлетворительных оценок и незачетов, без неявок и без пересдач. Таким образом, выплата ближайшего семестра уже детерминирована и прогноза не требует. Содержательной задачей прогнозирования является *раннее предупреждение*: по итогам семестра N оценить, будет ли семестр $N{+}1$ студента стипендиальным, – именно это событие открывает право на стипендию в семестре $N{+}2$.

Введем обозначения. Семестр студента назовем *стипендиальным*, если по его итогам выполнены академические условия назначения государственной ака-

демической стипендии, т.е. по всем дисциплинам семестра отсутствуют блокирующие результаты (оценка «удовлетворительно», «неудовлетворительно», «не зачтено», «неявка») и отсутствуют пересдачи; перезачтенные дисциплины блокирующими не считаются. Объектом выборки является пара последовательных семестров одного студента: признаковое описание $x \in \mathbb{R}^d$, $d = 13$, строится по семестру N, а целевая переменная определяется семестром $N{+}1$:

$$y \;=\; \begin{cases} 1, & \text{семестр } N{+}1 \text{ стипендиальный,} \\ 0, & \text{иначе.} \end{cases} \tag{1}$$

Семестр, не являющийся стипендиальным, называем *нестипендиальным*; переход из стипендиального состояния в нестипендиальное далее называем *потерей статуса*, обратный переход – *восстановлением*. Стипендиальный семестр $N{+}1$ открывает право на стипендию в семестре $N{+}2$ – при соблюдении прочих, неакадемических условий назначения. В коде конвейера и экспортируемых файлах этому статусу соответствуют идентификаторы со словом `clean`.

Обучающая выборка имеет вид

$$\mathcal{D} \;=\; \{(x_i, y_i)\}_{i=1}^{n}, \qquad x_i \in \mathbb{R}^d,\; y_i \in \{0, 1\}. \tag{2}$$

Задача состоит в оценке условной вероятности

$$p(x) \;=\; \mathbb{P}(y = 1 \mid x), \tag{3}$$

после чего бинарное решение принимается пороговым правилом $\widehat{y} = \mathbf{1}\{\widehat{p}(x) \geq t\}$, а величина

$$r(x) \;=\; 1 - \widehat{p}(x) \tag{4}$$

интерпретируется как *оценка риска*: для студента со стипендиальным текущим семестром – риск потери стипендиального статуса, для студента с нестипендиальным – оценка того, что восстановиться не удастся.

Дополнительно рассматривается четырехклассовая постановка (вариант Б), в которой класс перехода определяется парой состояний (текущий семестр; следую-

щий семестр): «стипендиальный – стипендиальный», «стипендиальный – нестипендиальный», «нестипендиальный – стипендиальный», «нестипендиальный – нестипендиальный». Поскольку текущее состояние известно точно, четырехклассовая метка восстанавливается детерминированно из известного текущего состояния и бинарного прогноза для (1); отдельная четырехклассовая модель не обучается.

1.2. Анализ методов классификации

Проведен сравнительный анализ основных семейств методов бинарной классификации применительно к табличным данным умеренного объема (таблица 1).

Таблица 1 – Сравнительный анализ семейств методов классификации

Метод	**Принцип**	**Преимущества**	**Ограничения**
Логистическая регрессия	Линейная модель логита вероятности	Интерпретируемость; выпуклая оптимизация	Не улавливает нелинейности и взаимодействия без ручного конструирования признаков
Решающее дерево	Рекурсивное разбиение пространства признаков	Нелинейность; устойчивость к масштабу признаков	Высокая дисперсия; переобучение одиночного дерева
Случайный лес	Бэггинг глубоких деревьев со случайными подмножествами признаков	Снижение дисперсии; малое число настроек	Без взвешивания классов смещается к мажоритарному классу; крупные модели
Градиентный бустинг	Последовательное добавление деревьев по градиенту функции потерь	Высокое качество на табличных данных; гибкая функция потерь; работа с пропусками (в современных реализациях)	Чувствительность к переобучению без регуляризации; последовательное обучение
Тривиальные правила (инерция)	Прогноз «следующее состояние равно текущему»	Нулевая стоимость; сильная база сравнения при инерционной динамике	Не ранжирует риск внутри групп; не предсказывает переходы

Для табличных данных с неоднородными по природе признаками, пропусками и умеренным объемом выборки в качестве основного метода выбран гра-

диентный бустинг над решающими деревьями; тривиальное инерционное правило при этом обязано присутствовать в эксперименте как базовая модель, поскольку академическая динамика заведомо инерционна.

1.3. Математические основы градиентного бустинга

В настоящем разделе математический аппарат излагается в точном соответствии с используемой далее реализацией (`HistGradientBoostingClassifier` библиотеки scikit-learn [3]): все приведенные формулы выверены по исходному коду [1] реализации и численно воспроизведены на контрольных примерах.

1.3.1. Решающее дерево как базовая модель

Решающее дерево разбивает пространство признаков на J непересекающихся областей $R_1, \ldots, R_J$ последовательностью осепараллельных предикатов вида $x^{(j)} \le \tau$ и задает кусочно-постоянную функцию

$$h(x) \;=\; \sum_{j=1}^{J} w_j \, \mathbf{1}\{x \in R_j\}, \tag{5}$$

где w_j – значение (вес) листа j. Одиночное глубокое дерево обладает высокой дисперсией и переобучается; бустинг обходит этот недостаток, используя *неглубокие* деревья как слабые базовые модели аддитивного ансамбля.

1.3.2. Бустинг как градиентный спуск в пространстве функций

Ансамбль строится в аддитивной форме

$$F_M(x) \;=\; F_0 \;+\; \nu \sum_{m=1}^{M} h_m(x), \tag{6}$$

где F_0 – начальное приближение, h_m – дерево шага m, а $\nu > 0$ – темп обучения (shrinkage), на практике выбираемый в $(0, 1]$. Минимизируется эмпирический риск

$$\mathcal{R}(F) \;=\; \sum_{i=1}^{n} w_i \, L\big(y_i, F(x_i)\big), \tag{7}$$

где $w_i > 0$ – веса наблюдений, а L – функция потерь. Ключевая идея Фридмана [2]: рассматривать $\mathcal{R}$ как функционал от значений $F(x_1), \ldots, F(x_n)$ и выполнять спуск в этом n-мерном пространстве. Антиградиент функционала по i-й координате равен $-\partial L(y_i, F(x_i))/\partial F(x_i)$, и очередное дерево h_m приближает направление антиградиента, вычисленного в текущей точке F_{m-1}.

1.3.3. Логистическая функция потерь и ее производные

Для бинарной классификации модель оперирует *логитом* $F(x) \in \mathbb{R}$, который связан с вероятностью сигмоидной функцией

$$p \;=\; \sigma(F) \;=\; \frac{1}{1 + e^{-F}}. \tag{8}$$

Используемая функция потерь в параметризации через логит имеет вид

$$L(y, F) \;=\; \ln\bigl(1 + e^{F}\bigr) \;-\; y\,F \tag{9}$$

и алгебраически тождественна перекрестной энтропии: подстановка $p = \sigma(F)$ дает $L = -\bigl[y \ln p + (1 - y) \ln(1 - p)\bigr]$. Дифференцирование (9) по F дает градиент и вторую производную (гессиан) потерь на наблюдении:

$$g \;=\; \frac{\partial L}{\partial F} \;=\; \sigma(F) - y \;=\; p - y, \qquad h \;=\; \frac{\partial^2 L}{\partial F^2} \;=\; \sigma(F)\bigl(1 - \sigma(F)\bigr) \;=\; p(1 - p). \tag{10}$$

Таким образом, «остатки», которые приближает очередное дерево, – это в точности разности $p_i - y_i$ между текущими вероятностными прогнозами и метками. При наличии весов наблюдений градиенты и гессианы масштабируются:

$$g_i \;=\; w_i\,(p_i - y_i), \qquad h_i \;=\; w_i\,p_i(1 - p_i). \tag{11}$$

1.3.4. Ньютоновский шаг: значения листьев и критерий разбиения

Реализация использует приближение второго порядка (ньютоновский бустинг). Разложим риск (7) в окрестности текущего ансамбля F_{m-1} по добавляемому

дереву h:

$$\mathcal{R}(F_{m-1} + h) \;\approx\; \mathcal{R}(F_{m-1}) \;+\; \sum_{i=1}^{n} g_i\, h(x_i) \;+\; \frac{1}{2} \sum_{i=1}^{n} h_i\, h(x_i)^2. \tag{12}$$

Для дерева фиксированной структуры (5) функция h постоянна на каждом листе, поэтому задача распадается на независимые одномерные задачи по листьям. Обозначим суммарные градиент и гессиан листа

$$G_j \;=\; \sum_{i:\, x_i \in R_j} g_i, \qquad H_j \;=\; \sum_{i:\, x_i \in R_j} h_i. \tag{13}$$

Минимизация (12) по w_j с L_2-штрафом $\frac{\lambda}{2} w_j^2$ на значения листьев дает оптимальный вес листа

$$w_j^* \;=\; -\,\frac{G_j}{H_j + \lambda}, \tag{14}$$

то есть регуляризованный шаг Ньютона по координате листа. Параметр $\lambda > 0$ стягивает значения листьев к нулю и тем самым ограничивает вклад отдельного листа; в настоящей работе $\lambda = 5$. (В реализации к знаменателю добавляется стабилизирующая константа 10^{-15}, исключающая деление на нуль.)

Подстановка (14) в (12) показывает, что вклад листа в аппроксимированный риск пропорционален величине $-G_j^2/(H_j + \lambda)$. В используемой реализации «потери узла» определяются ровно этим выражением (без множителя $\frac{1}{2}$), и выигрыш от разбиения узла на левый (L) и правый (R) дочерние узлы вычисляется как уменьшение потерь:

$$\mathrm{Gain} \;=\; \frac{G_L^2}{H_L + \lambda} \;+\; \frac{G_R^2}{H_R + \lambda} \;-\; \frac{(G_L + G_R)^2}{H_L + H_R + \lambda}. \tag{15}$$

Исходный код реализации прямо ссылается на исходную работу о системе XGBoost: формула значений листьев (14) соответствует уравнению (5) этой работы, что зафиксировано в документации реализации [2], а узловые потери и критерий выигрыша (15) – уравнениям (6) и (7), указанным в исходном коде [1]. От этого классического критерия реализация отличается двумя соглашениями: опущен общий множитель $\frac{1}{2}$, не влияющий на выбор максимума, и отсутствует

аддитивный штраф γ за лист (его отсутствие прямо отмечено в документации реализации [2]) – сложность дерева ограничивается напрямую параметрами максимальной глубины, максимального числа листьев и минимального числа объектов в листе. Разбиение принимается, только если $\mathrm{Gain} > 0$; в противном случае узел объявляется листом.

1.3.5. Инициализация ансамбля

Начальное приближение F_0 выбирается как константа, минимизирующая риск (7); для потерь (9) это логит взвешенной доли положительного класса:

$$F_0 \;=\; \ln \frac{\bar{y}_w}{1-\bar{y}_w}, \qquad \bar{y}_w \;=\; \frac{\sum_i w_i y_i}{\sum_i w_i}. \tag{16}$$

При сбалансированных весах (см. ниже) $\bar{y}_w = \frac{1}{2}$ и $F_0 = 0$.

1.3.6. Гистограммная аппроксимация поиска разбиений

Точный перебор порогов требует сортировки значений каждого признака в каждом узле. Гистограммный метод [2] заменяет его предварительной *квантизацией*: значения каждого признака один раз отображаются в не более чем $B = 255$ корзин (bins), границы которых ставятся в серединах между соседними эмпирическими квантилями признака (если различных значений меньше B – в серединах между соседними различными значениями). Отдельная, 256-я корзина резервируется под пропуски (NaN); направление, в которое пропуски отправляются при каждом разбиении, не фиксируется заранее, а выбирается по критерию (15) наравне с порогом. Так как квантильные границы оцениваются по подвыборке не более $2 \cdot 10^5$ объектов, а объем обучающей выборки в настоящей работе равен $9\,169$, квантизация здесь выполняется по точным квантилям без подвыборки.

После квантизации в каждом узле по каждому признаку строится гистограмма пар $(\sum g, \sum h)$ по корзинам за один проход по объектам узла, после чего перебор порогов сводится к одному проходу по корзинам: суммарная стоимость поиска разбиения составляет $O(B \cdot d)$ вместо сортировок. Дополнительное ускорение дает *прием вычитания*: гистограмма второго дочернего узла получается поэлементным вычитанием гистограммы первого из гистограммы родителя за $O(B)$, без повторного прохода по объектам. Платой за квантизацию является лишь огруб-

ление множества допустимых порогов до границ корзин.

1.3.7. Регуляризация: темп обучения и ранняя остановка

Темп обучения ν применяется умножением значений листьев построенного дерева на ν, что в точности эквивалентно записи $F_m = F_{m-1} + \nu\, h_m$ в (6). Малые ν уменьшают вклад каждого дерева и в сочетании с ранней остановкой действуют как регуляризатор траектории спуска; в настоящей работе $\nu = 0{,}05$.

Число деревьев M выбирается ранней остановкой. Перед обучением от обучающей выборки отделяется внутренняя валидационная часть (15% строк, стратифицированно по классам); после каждой итерации на ней вычисляется контрольная метрика (в настоящей работе – ROC-AUC, см. п. 2.3). Обучение останавливается, как только ни одно из последних 50 значений метрики (включая текущее) не превосходит значение, полученное 50 итерациями ранее, более чем на допуск 10^{-7}; верхний предел составляет $M_{\max} = 1000$ итераций. Существенная оговорка: внутреннее разбиение выполняется *по строкам*, поэтому пары семестров одного студента могут оказаться по обе стороны внутреннего разбиения. Это влияет только на момент остановки обучения; внешняя оценка качества (раздел 3) выполняется на отложенных *студентах* и от данного эффекта свободна.

1.3.8. Учет дисбаланса классов

Дисбаланс классов компенсируется весами наблюдений по схеме «balanced»:

$$w_i \;=\; \frac{n}{K \cdot n_{y_i}}, \tag{17}$$

где $K = 2$ – число классов, n_{y_i} – численность класса наблюдения i. Суммарный вес каждого класса при этом равен $n/2$, то есть классы вносят одинаковый совокупный вклад в риск (7); через (11) веса масштабируют градиенты и гессианы и тем самым смещают и значения листьев (14), и критерий разбиения (15) в пользу миноритарного класса.

1.4. Обзор программных реализаций

Зрелые реализации градиентного бустинга над деревьями – XGBoost, LightGBM, CatBoost – на табличных данных умеренного объема, как правило, сопоставимы по качеству, поэтому решающими при выборе были математическая

прозрачность и воспроизводимость окружения. Для настоящей работы выбрана реализация `HistGradientBoostingClassifier` библиотеки scikit-learn: ее устройство в точности совпадает с изложенным в п. 1.3 аппаратом (ньютоновский бустинг с гистограммным поиском разбиений и L_2-регуляризацией листьев), пропуски обрабатываются штатно через выделенную корзину – что существенно, поскольку признаковое описание содержит пропуски, – библиотека распространяется под свободной лицензией BSD-3, а реализация входит в ее состав и не требует установки дополнительных пакетов.

Итог подготовительного этапа. Задача формализована как бинарная классификация пар последовательных семестров (1)–(4). В качестве модели выбран гистограммный градиентный бустинг в реализации `HistGradientBoosting-Classifier` (scikit-learn): реализация воспроизводит ньютоновский бустинг (12)–(15) с гистограммным поиском разбиений, штатно обрабатывает пропуски (которые в данных присутствуют для среднего балла и минимальной оценки в семестрах, состоящих только из недифференцированных зачетов) и не требует дополнительных пакетов. Весь изложенный в п. 1.3 аппарат сверен с исходным кодом реализации и численно воспроизведен.

2. Ориентировочный этап

Целью ориентировочного этапа является подготовка данных и измерительной базы исследования: описание и предобработка исходного массива, построение признакового описания семестра, определение системы метрик качества и базовых моделей сравнения.

2.1. Описание и предобработка данных

Исходный массив представляет собой выгрузку зачетно-экзаменационных ведомостей в формате ГОСТ Р 70946–2023 (Приложение 8) объемом 181 569 записей по 7 358 зачетным книжкам с 17 атрибутами (зачетная книжка, период контроля, дисциплина, вид контроля, тип ведомости, итоговая отметка, баллы аттестаций и пересдач и др.). Запись соответствует одной строке ведомости: (студент, семестр, дисциплина, тип ведомости).

В исследовании используются записи очной формы обучения, период контроля которых соответствует семестрам с первого по десятый: 155 450 записей по 5 934 студентам (бакалавриат – 131 723 записи, специалитет – 23 727). Отброшены 24 114 записей с сессионными периодами контроля заочной формы и 2 005 записей очно-заочной формы. Ведомости итоговой аттестации (ГАК – 889 записей, защита ВКР – 890) обрабатываются наравне с дисциплинами семестра: они входят в число дисциплин и в средний балл и могут давать блокирующий результат (305 отметок «удовлетворительно»). Формально это государственная итоговая, а не промежуточная аттестация; их включение – осознанное решение об охвате данных, затрагивающее только переходы в выпускные семестры. Распределение итоговых отметок: «зачтено» – 43 293, «отлично» – 39 878, «хорошо» – 35 678, «удовлетворительно» – 33 289, «неявка» – 1 509, «неудовлетворительно» – 1 069, «не зачтено» – 734. Текстовые отметки кодируются числами для агрегации худшего результата: отлично – 5, хорошо – 4, удовлетворительно – 3, неудовлетворительно – 2, зачтено – 4, не зачтено – 2, неявка – 2. Зачетные позиции исключаются из среднего балла *правилом* (вид контроля «Зачет» либо отметка «зачтено»/«не зачтено»), а не отсутствием числового кода; как следствие, неявка по дифференцированной форме контроля входит в средний балл с кодом 2 (в данных – 1 235 таких записей).

Типы ведомостей обрабатываются по правилам таблицы 2.

Таблица 2 – Правила обработки типов ведомостей

Тип ведомости	**Записей**	**Правило обработки**
Основная	155 295	Базовая запись результата по дисциплине
Перезачет	129	Учитывается в числе дисциплин; в средний балл входит при дифференцированной отметке; никогда не считается блокирующим результатом или пересдачей
Пересдача; пересдача с комиссией	$24 + 2$	Если дублирует основную запись той же тройки (студент, семестр, дисциплина) – удаляется, у дисциплины поднимается флаг пересдачи; одиночная запись сохраняется с тем же флагом

Дополнительно флаг пересдачи поднимается, если в столбцах баллов «Пересдача» или «Комиссия» стоит положительное значение либо итоговая отметка – «неявка». Последнее правило – сознательное огрубление: неявка трактуется как событие, влекущее пересдачу, хотя формально пересдача могла не состояться; случай нулевых баллов в столбцах пересдач неотличим от их отсутствия и игнорируется. Удаление дублей пересдач затрагивает 24 записи, 2 одиночные записи пересдач сохранены; итог предобработки – 155 426 записей, агрегируемых в 17 510 пар (студент, семестр). По всей выборке пар доля стипендиальных следующих семестров составляет $43{,}3\%$.

Перед агрегацией по дисциплине для каждой тройки (студент, семестр, дисциплина) вычисляются и запоминаются худшая числовая оценка, флаг блокирующего результата и флаг пересдачи – так информация не теряется при последующей дедупликации. Затем дубликаты записей одной дисциплины сворачиваются в одну запись по убыванию приоритета вида контроля: экзамен; зачет с оценкой; курсовая работа, курсовой проект, ГАК и защита ВКР (равный приоритет); зачет; прочие виды контроля; при равном приоритете сохраняется строка с худшей оценкой, а числовая оценка свернутой записи в любом случае заменяется худшей из наблюдавшихся по всем строкам дисциплины. Семестр студента считается стипендиальным по определению п. 1.1: ни одного блокирующего результата и ни одной пересдачи.

Объектами выборки служат пары *строго последовательных* семестров одного студента (пары с разрывом нумерации не образуются). Всего построено 11 512

пар по $5\,634$ студентам (студенты с единственным семестром пар не образуют). Разбиение на обучающую и тестовую части выполнено *по студентам* в пропорции 80/20: $9\,169$ пар ($4\,507$ студентов) в обучении и $2\,343$ пары ($1\,127$ студентов) в тесте; ни один студент не присутствует в обеих частях. В тестовой части доля стипендиальных следующих семестров составляет $996/2\,343 = 42{,}5\%$.

2.2. Признаковое описание семестра

Каждой паре сопоставляется вектор из $d = 13$ признаков, вычисленных по семестру N (таблица 3). Обозначим S – множество дисциплин семестра; $S_{\text{зач}} \subseteq S$ – подмножество зачетных позиций (вид контроля «Зачет» либо отметка «зачтено»/«не зачтено»); $S_{\text{гр}} = S \setminus S_{\text{зач}}$ – дифференцированные позиции; g_s – худший числовой код позиции s (для неявки – код 2).

Таблица 3 – Признаковое описание семестра студента

Признак	**Определение**
`sem_num`	Номер семестра N
`n_subjects`	Число дисциплин $\lvert S\rvert$
`n_blocks`	Число дисциплин с блокирующим результатом
`n_retakes`	Число дисциплин с пересдачей
`any_block`	$\mathbf{1}\{\texttt{n_blocks} > 0\}$
`any_retake`	$\mathbf{1}\{\texttt{n_retakes} > 0\}$
`gpa_overall`	$\frac{1}{\lvert S_{\text{гр}}\rvert}\sum_{s\in S_{\text{гр}}} g_s$ (пропуск при $S_{\text{гр}} = \varnothing$)
`min_grade`	$\min_{s\in S_{\text{гр}}} g_s$ (пропуск при $S_{\text{гр}} = \varnothing$)
`std_grade`	Выборочное стандартное отклонение $\{g_s\}_{s\in S_{\text{гр}}}$ (пропуск при $\lvert S_{\text{гр}}\rvert < 2$; перед обучением пропуск заменяется нулем)
`share_5`	$\lvert\{s \in S_{\text{гр}} : g_s = 5\}\rvert \,/\, \lvert S_{\text{гр}}\rvert$ (0 при $S_{\text{гр}} = \varnothing$)
`share_3`	$\lvert\{s \in S_{\text{гр}} : g_s = 3\}\rvert \,/\, \lvert S_{\text{гр}}\rvert$ (0 при $S_{\text{гр}} = \varnothing$)
`share_zachet`	$\lvert S_{\text{зач}}\rvert \,/\, \lvert S\rvert$ – доля зачетных позиций
`had_clean_current_sem`	Индикатор стипендиального статуса текущего семестра N

Два замечания. Во-первых, доли `share_5` и `share_3` вычисляются по *худшей* оценке дисциплины, поэтому при расхождении текстовой итоговой отметки и худшего числового результата приоритет имеет последний. Во-вторых, признак

`had_clean_current_sem` включен сознательно: текущее состояние – сильнейший одиночный предиктор будущего, и его исключение лишь искусственно занизило бы качество.

Незаполненными остаются только пропуски признаков `gpa_overall` и `min_grade` (16 пар, семестр которых состоит из одних недифференцированных зачетов): они штатно обрабатываются гистограммным методом через выделенную корзину пропусков (п. 1.3).

2.3. Метрики качества и базовые модели

Пусть для порога t через TP, FP, TN, FN обозначены числа истинно-положительных, ложноположительных, истинно-отрицательных и ложноотрицательных решений – элементы матрицы ошибок; положительным классом считается «стипендиальный семестр» ($y = 1$). Определения метрик соответствуют их реализации в scikit-learn [4]. Используются метрики:

$$\text{Accuracy} \;=\; \frac{TP + TN}{TP + TN + FP + FN}, \tag{18}$$

$$\text{Precision} \;=\; \frac{TP}{TP + FP}, \qquad \text{Recall} \;=\; \frac{TP}{TP + FN}, \tag{19}$$

$$F_1 \;=\; \frac{2\,\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}, \tag{20}$$

а также макроусреднение F_1 по классам:

$$F_1^{\text{macro}} \;=\; \frac{1}{K} \sum_{k=1}^{K} F_1^{(k)}. \tag{21}$$

ROC-кривая есть параметрическая кривая $t \mapsto (\text{FPR}(t), \text{TPR}(t))$, где $\text{TPR} = \text{Recall}$, $\text{FPR} = FP/(FP + TN)$; площадь под ней (AUC) допускает вероятностную интерпретацию: для случайно выбранных положительного и отрицательного объектов со скорами s^+ и s^-

$$\text{AUC} \;=\; \mathbb{P}\big(s^+ > s^-\big) \;+\; \tfrac{1}{2}\,\mathbb{P}\big(s^+ = s^-\big) \;=\; \frac{U}{n_+\, n_-}, \tag{22}$$

где U – статистика Манна-Уитни. Два следствия интерпретации (22) существенны далее: AUC инвариантна к любому монотонному преобразованию скоров (то есть измеряет качество *ранжирования*, а не калибровку вероятностей) и корректно определена внутри любой подгруппы, тогда как для константного на подгруппе прогноза $\mathrm{TPR} \equiv \mathrm{FPR}$ и $\mathrm{AUC} = \frac{1}{2}$ – именно поэтому AUC по подгруппам отделяет вклад модели от вклада инерции.

Значимость признаков оценивается перестановочным методом [5]: для признака j

$$\Delta_j \;=\; \mathrm{AUC} \;-\; \mathbb{E}_\pi\, \mathrm{AUC}^{(\pi_j)}, \tag{23}$$

где $\mathrm{AUC}^{(\pi_j)}$ – качество после случайной перестановки π столбца j тестовой выборки (здесь – усреднение по пяти перестановкам). Далее значимости приводятся в *нормированном* виде – как доли суммарного падения качества:

$$\widetilde{\Delta}_j \;=\; \frac{\max(\Delta_j,\, 0)}{\sum_k \max(\Delta_k,\, 0)}, \qquad \sum_j \widetilde{\Delta}_j = 1. \tag{24}$$

При коррелированных признаках вклад делится между ними (этот эффект описан в документации метода [5]), что учитывается при интерпретации.

Базовые модели сравнения определены как решающие правила (таблица 4).

Таблица 4 – Базовые модели сравнения

Базовая модель	**Решающее правило**
Мажоритарный класс	$\widehat{y} \equiv 0$ (класс большинства обучающей выборки)
Инерция (persistence)	$\widehat{y} = \texttt{had_clean_current_sem}$
Правило «нет блокировок»	$\widehat{y} = \mathbf{1}\{\texttt{n_blocks} = 0 \wedge \texttt{n_retakes} = 0\}$ (совпадает с инерцией по построению признака)
Порог среднего балла	$\widehat{y} = \mathbf{1}\{\texttt{gpa_overall} \geq \theta\}$, $\theta \in \{4{,}0;\ 4{,}2\}$; пропуск среднего балла трактуется как $\widehat{y} = 0$

Итог ориентировочного этапа. Из $181\,569$ записей ведомостей сформирована выборка из $11\,512$ пар последовательных семестров по $5\,634$ студентам очной формы; определено признаковое описание из 13 величин с точными формулами; зафиксирована система метрик (18)–(24) и пять базовых правил сравнения (табли-

ца 4; пороговое правило взято с двумя значениями порога).

3. Основной этап

3.1. Условия проведения эксперимента

Эксперимент проведен в следующих фиксированных условиях.

1. Разбиение на обучение и тест выполнено *по студентам* (80/20): множество студентов разбито на две непересекающиеся части, и все пары студента целиком попадают в одну часть. Это исключает утечку, при которой соседние пары одного студента оказались бы по разные стороны разбиения.

2. Зафиксировано начальное состояние генератора псевдослучайных чисел (seed = 42) для разбиения, внутренней валидации и обучения.

3. Веса наблюдений (17) вычислены по обучающей части и применялись только при обучении; все метрики на тесте – невзвешенные.

4. Гиперпараметры модели приведены в таблице 5; подбор гиперпараметров не проводился, конфигурация зафиксирована априорно.

5. Выполнен сквозной контроль воспроизводимости: конвейер предобработки повторно исполнен на исходном файле ведомостей; восстановленная тестовая выборка совпала с экспортированными прогнозами по всем идентификаторам, состояниям и целевым меткам, а вероятности модели совпали без расхождений (нулевая максимальная разность при точности экспорта 10^{-4}); повторное обучение модели с той же конфигурацией воспроизвело число итераций $M = 248$ и вероятности на тесте точно.

Таблица 5 – Конфигурация модели

Параметр	**Значение**
Темп обучения ν	0,05 (6)
Максимальная глубина дерева	5 (5)
Минимум объектов в листе	10 (5)
Максимум листьев дерева	31 (по умолчанию) (5)
L_2-регуляризация листьев λ	5,0 (14), (15)
Балансировка классов	веса «balanced», формула (17)
Предел итераций $M_{\max}$	1000 (6)
Внутренняя валидация	15% строк, стратифицированно (п. 1.3.7)
Метрика ранней остановки	ROC-AUC, терпение 50 итераций (п. 1.3.7)
Фактическое число итераций M	248 (6)

3.2. Сравнительный анализ с базовыми моделями

Результаты на обучающей и тестовой выборках приведены в таблице 6; ROC-кривая модели на тестовой выборке – на рисунке 1.

Таблица 6 – Качество модели и базовых правил на обучающей и тестовой выборках

Модель / правило	**Accuracy**		**F_1 macro**		**ROC-AUC**	
	обуч.	тест.	обуч.	тест.	обуч.	тест.
Мажоритарный класс	56,5%	57,5%	0,361	0,365	–	–
Инерция (persistence)	82,9%	82,3%	0,825	0,819	–	–
Правило «нет блокировок»	82,9%	82,3%	0,825	0,819	–	–
Порог GPA $\geq 4{,}0$	80,0%	79,3%	0,800	0,793	–	–
Порог GPA $\geq 4{,}2$	81,8%	81,8%	0,815	0,815	–	–
Градиентный бустинг	**85,4%**	**83,1%**	**0,853**	**0,830**	**0,931**	**0,914**

Разрыв между обучающей и тестовой выборками умерен (accuracy $85{,}4\%$ против $83{,}1\%$, ROC-AUC $0{,}931$ против $0{,}914$), что согласуется с применением ранней остановки (п. 1.3.7). Далее все показатели приводятся на тестовой выборке.

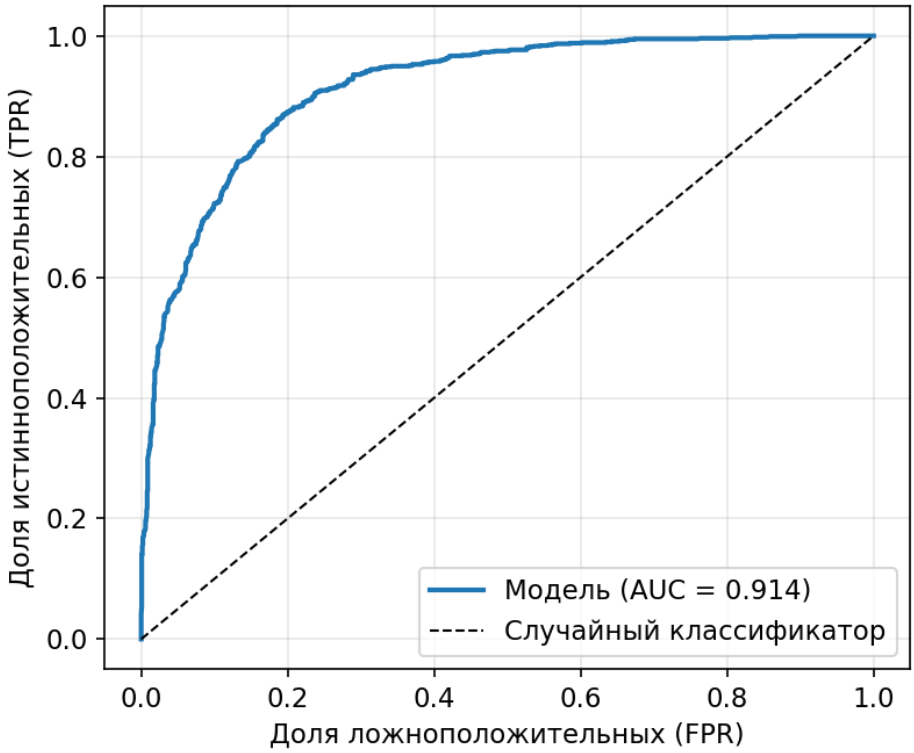


Рисунок 1 – ROC-кривая модели на тестовой выборке

По доле верных ответов при пороге по умолчанию ($t = 0{,}5$) модель превосходит инерционное правило на $0{,}85$ процентного пункта ($83{,}1\%$ против $82{,}3\%$), по F_1^{macro} – на $0{,}011$. Прирост невелик, что закономерно: динамика инерционна, и большую часть верных ответов дает само текущее состояние. Детализация по классам приведена в таблице 7; матрица ошибок – на рисунке 2.

Таблица 7 – Поклассовые метрики модели (порог $t = 0{,}5$)

Класс	**Precision**	**Recall**	F_1	**Объектов**
Нестипендиальный ($N{+}1$)	0,890	0,807	0,846	1 347
Стипендиальный ($N{+}1$)	0,768	0,864	0,813	996

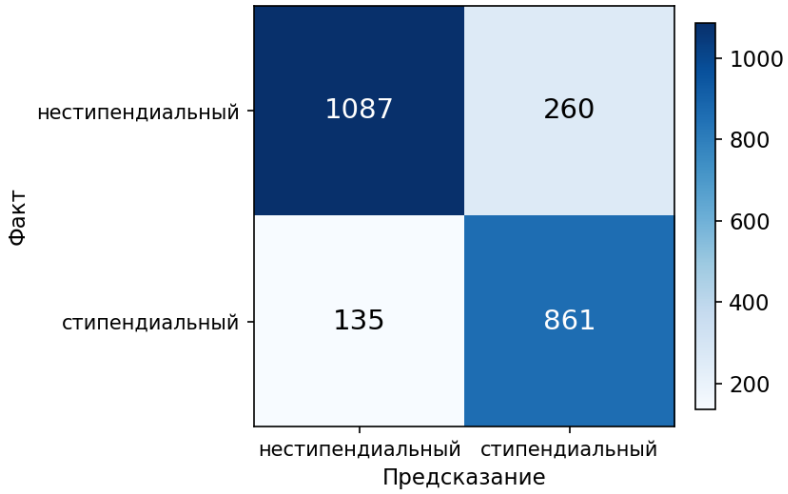


Рисунок 2 – Матрица ошибок бинарного прогноза (порог $t = 0{,}5$)

Четырехклассовая детализация (вариант Б) восстанавливается комбинированием известного текущего состояния с бинарным прогнозом (таблица 8).

Таблица 8 – Вариант Б: точность по классам переходов (порог $t = 0{,}5$)

Переход	**Объектов**	**Точность**
Стипендиальный – стипендиальный	784	100,0%
Стипендиальный – нестипендиальный	203	1,5%
Нестипендиальный – стипендиальный	212	36,3%
Нестипендиальный – нестипендиальный	1 144	94,8%

Таблица 8 вскрывает главный недостаток порога по умолчанию: из 203 студентов, утративших стипендиальный статус после стипендиального семестра, при $t = 0{,}5$ модель указывает лишь троих. Внутри группы «стипендиальный сейчас» пороговый прогноз практически вырождается в инерционное правило. Следующий пункт показывает, что это свойство *порога*, а не модели.

3.3. Анализ модели: подгруппы, порог, значимость признаков

Качество ранжирования внутри подгрупп. По свойству (22) инерционное правило внутри каждой подгруппы текущего состояния константно и дает $\mathrm{AUC} = 0{,}5$, тогда как у модели (рисунок 3): в группе «текущий семестр стипендиальный»

(987 пар, из них 203 будущие потери статуса) $\mathrm{AUC} = 0{,}779$; в группе «текущий семестр нестипендиальный» (1 356 пар, из них 212 восстановлений) $\mathrm{AUC} = 0{,}840$. Таким образом, модель несет существенную ранжирующую информацию именно там, где базовые правила слепы; малый прирост в таблице 6 – следствие неудачной точки на ROC-кривой, а не отсутствия сигнала.

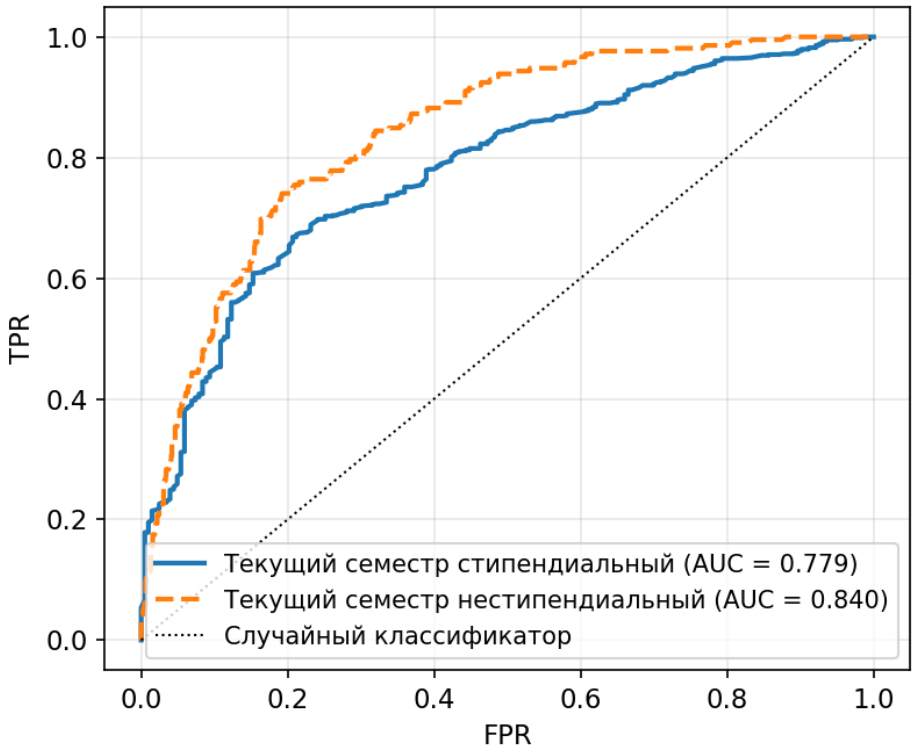


Рисунок 3 – ROC-кривые внутри подгрупп текущего состояния

Выбор рабочей точки. Для группы «стипендиальный сейчас» рассмотрим решающее правило объявления тревоги $r(x) > t$, где $r(x)$ – оценка риска (4). Зависимости полноты и точности тревог от t показаны на рисунке 4 и в таблице 9; альтернативная форма того же анализа – кривая охвата при ранжировании группы по убыванию риска (рисунок 5, таблица 10).

Таблица 9 – Правило тревоги $r > t$ в группе «стипендиальный сейчас» (987 пар, 203 потери статуса)

Порог t	**Тревог**	**Полнота по потерям статуса**	**Точность тревог**
0,50	3	1%	100%
0,40	25	7%	60%
0,30	117	29%	50%
0,20	287	59%	42%
0,15	387	75%	39%

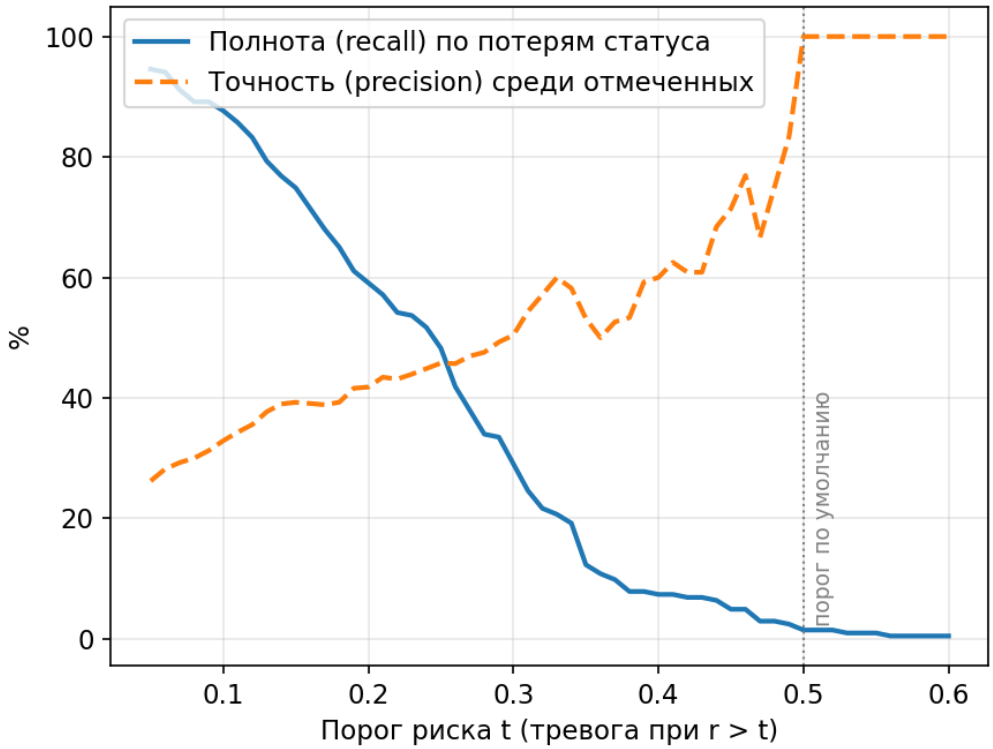


Рисунок 4 – Полнота и точность тревог в группе «стипендиальный сейчас» в зависимости от порога

Таблица 10 – Охват будущих потерь статуса при ранжировании группы «стипендиальный сейчас» по риску

Доля группы (по убыванию риска)	**Охват потерь**	**Точность**
10% (99 студентов)	26%	53%
20% (197 студентов)	44%	45%
30% (297 студентов)	61%	42%

Группы взяты включительно по граничному значению риска. На границе верхней децили четыре пары имеют одинаковое значение риска ($0{,}31$ при точности экспорта 10^{-4}), поэтому она содержит 99 объектов; аналогичное совпадение на границе 30% дает 297 объектов.

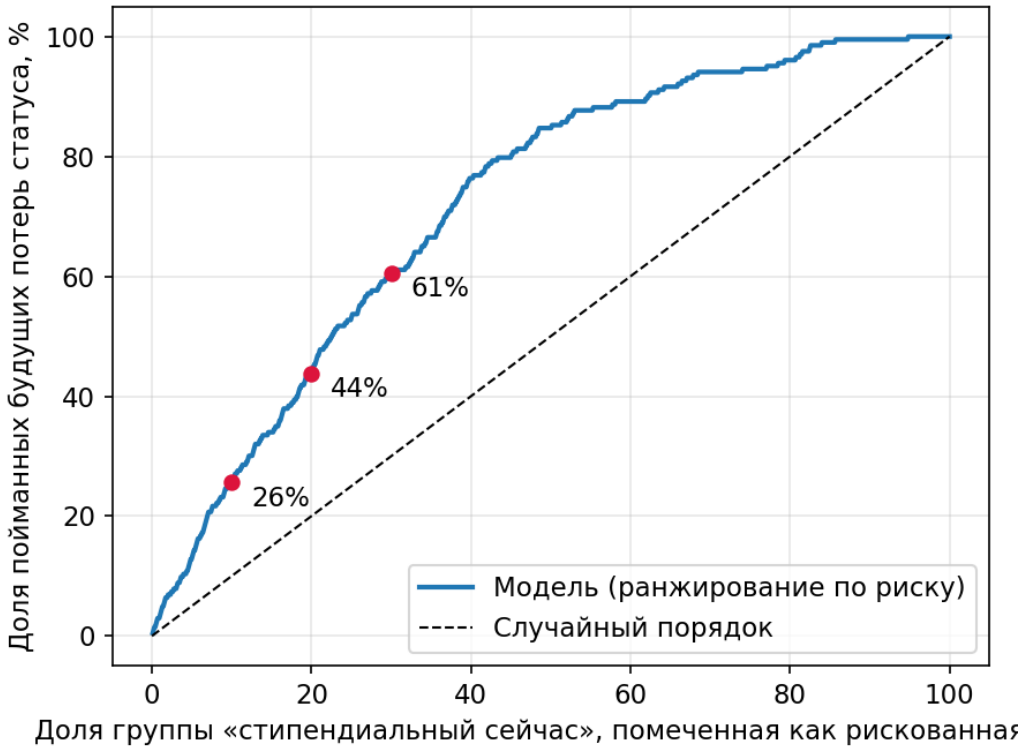


Рисунок 5 – Кривая охвата будущих потерь статуса в группе «стипендиальный сейчас»

Снижение порога с $0{,}5$ до $0{,}15$-$0{,}20$ переводит модель из режима «повторяет инерцию» в режим раннего предупреждения: при тревоге для 29-39% группы охватывается 59-75% будущих потерь статуса, причем каждая вторая-третья тревога подтверждается. Для сравнения, инерционное правило в этой группе не выдает ни одной тревоги по построению. Подчеркнем методологическую оговорку: приведенные значения порога получены на тестовой выборке и служат иллюстрацией формы зависимости; при внедрении рабочая точка должна фиксироваться по отдельной валидационной выборке до взгляда на тест.

Значимость признаков. Нормированная перестановочная значимость (24) по ROC-AUC приведена на рисунке 6. Доминирует средний балл `gpa_overall` ($\widetilde{\Delta} = 0{,}564$), далее – число пересдач ($0{,}169$) и номер семестра ($0{,}071$). Малая доля

признака `had_clean_current_sem` (0,028) не противоречит его силе как одиночного предиктора: информация о текущем состоянии почти полностью дублируется коррелированными счетчиками `n_blocks`, `n_retakes` и средним баллом, и перестановочный метод делит вклад между ними. Нулевые значения у индикаторов `any_block` и `any_retake` объясняются тем же: они являются огрублением соответствующих счетчиков. Содержательный вывод: модель опирается не на сам стипендиальный статус текущего семестра, а на *степень* благополучия (насколько высок средний балл, сколько именно пересдач), что и порождает ранжирующий сигнал внутри подгрупп.

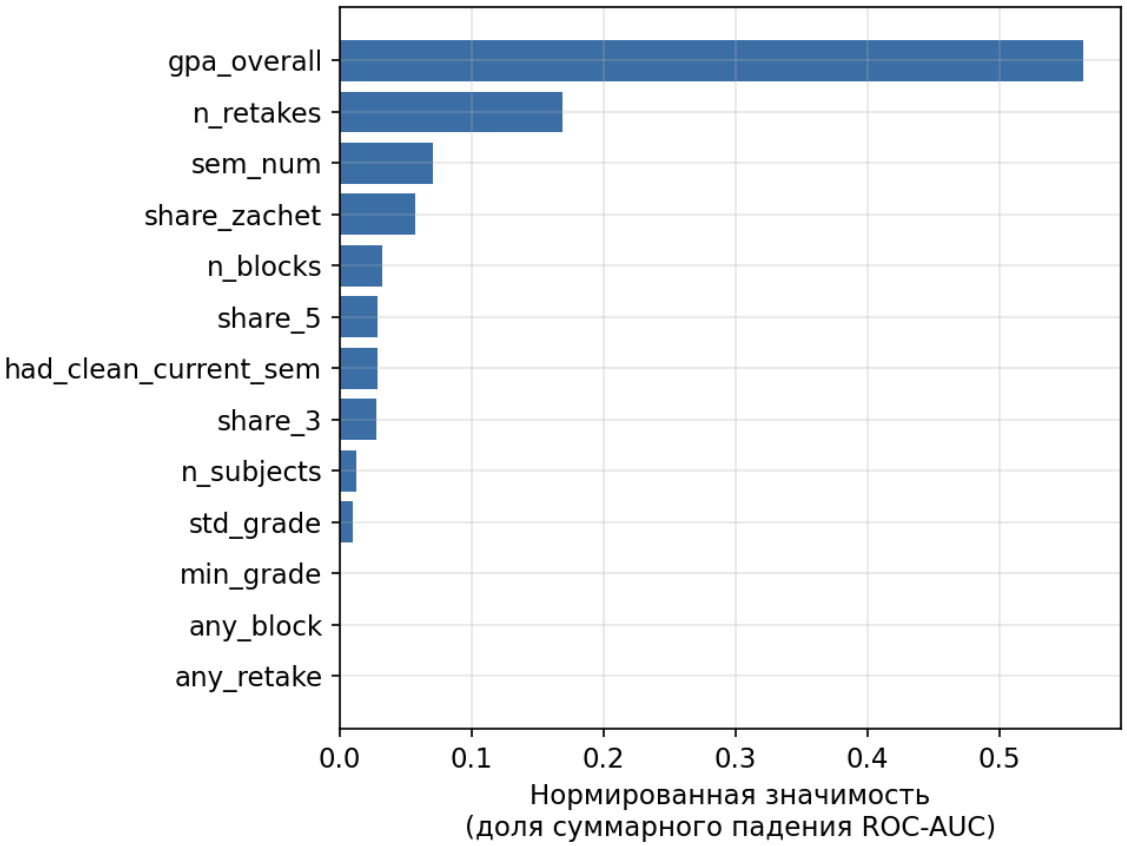


Рисунок 6 – Нормированная перестановочная значимость признаков (доли суммарного падения ROC-AUC)

Рекомендации по применению. Сводка рабочих режимов по результатам таблиц 9 и 10 приведена в таблице 11.

Таблица 11 – Матрица выбора рабочего режима

Сценарий	**Правило**	**Полнота**	**Точность**
Классификация при пороге по умолчанию	$t = 0{,}5$	1%	100%
Адресная поддержка (малый ресурс)	ранжирование, верхние 10% риска	26%	53%
Сбалансированный скрининг	$t \approx 0{,}3$	29%	50%
Широкий скрининг	$t \in [0{,}15;\ 0{,}20]$	59-75%	39-42%
Приоритет восстановления (группа нестипендиальный сейчас)	ранжирование по $\widehat{p}$ ($\mathrm{AUC} = 0{,}840$)	–	–

Ограничения исследования. (1) Использовано одно фиксированное разбиение и одно начальное состояние генератора; дисперсия метрик не оценена. (2) Правило «неявка трактуется как пересдача» – огрубление данных; нулевые баллы в столбцах пересдач неразличимы с их отсутствием. (3) Доли оценок вычисляются по худшему результату дисциплины и могут расходиться с текстовой итоговой отметкой. (4) Вероятности модели не калибровались; все выводы опираются на ранжирование (инвариантное к монотонным преобразованиям скоров, см. (22)), для практического внедрения рабочую точку следует фиксировать на отдельной валидационной выборке. (5) Основная доля точности при пороге по умолчанию объясняется инерцией процесса; добавленная ценность модели сосредоточена в ранжировании внутри подгрупп. (6) Успеваемость операционализирована бинарным статусом семестра.

Заключение

В ходе учебной практики проведено исследование, посвященное прогнозированию стипендиального статуса семестра студента на семестр вперед – события, определяющего право на государственную академическую стипендию в семестре, следующем за ним. Выполнены все этапы, предусмотренные индивидуальным заданием.

На подготовительном этапе задача формализована как бинарная классификация пар последовательных семестров (1)–(4); проведен сравнительный анализ семейств методов; изложен математический аппарат градиентного бустинга в точном соответствии с используемой реализацией: логистическая функция потерь и ее производные (9)–(11), ньютоновский шаг по листьям (14), критерий разбиения (15), инициализация (16), гистограммная аппроксимация поиска разбиений, темп обучения, ранняя остановка и балансировка классов (17); формулы сверены с исходным кодом реализации и воспроизведены численно.

На ориентировочном этапе из $181\,569$ записей ведомостей построена выборка из $11\,512$ пар семестров по $5\,634$ студентам очной формы обучения; заданы правила обработки типов ведомостей и дедупликации дисциплин; определено признаковое описание из 13 величин и система метрик (18)–(24) с пятью базовыми правилами сравнения.

На основном этапе при честном разбиении по студентам модель достигла $\mathrm{Accuracy} = 83{,}1\%$, $F_1^{\text{macro}} = 0{,}830$, $\mathrm{AUC} = 0{,}914$ против $82{,}3\%$ у инерционного правила. Показано, что добавленная ценность модели заключена не в пороговой классификации, а в ранжировании риска внутри подгрупп текущего состояния ($\mathrm{AUC} = 0{,}779$ и $0{,}840$ там, где базовые правила дают $0{,}5$): верхние 30% группы благополучных студентов по риску содержат 61% будущих потерь стипендии. Сформулированы рекомендации по выбору рабочей точки и перечень ограничений исследования.

Результаты работы подтверждают формирование компетенций ОПК-1 (способность применять фундаментальные знания, полученные в области математических и (или) естественных наук, и использовать их в профессиональной деятельности) и ОПК-4 (способность понимать принципы работы современных информационных технологий и использовать их для решения задач профессиональной

деятельности).

Список использованных источников

[1] Исходный код модуля sklearn.ensemble._hist_gradient_boosting (scikit-learn, версия 1.8.0) : репозиторий GitHub : [сайт]. – URL: https://github.com/scikit-learn/scikit-learn/tree/1.8.0/sklearn/ensemble/_hist_gradient_boosting (дата обращения: 16.05.2026). – Текст: электронный.

[2] Ensembles: Gradient boosting, random forests, bagging, voting, stacking (раздел Histogram-Based Gradient Boosting) : руководство пользователя scikit-learn : [сайт]. – URL: https://scikit-learn.org/stable/modules/ensemble.html (дата обращения: 16.05.2026). – Текст: электронный.

[3] HistGradientBoostingClassifier : документация библиотеки scikit-learn : [сайт]. – URL: https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.HistGradientBoostingClassifier.html (дата обращения: 16.05.2026). – Текст: электронный.

[4] Metrics and scoring: quantifying the quality of predictions : руководство пользователя scikit-learn : [сайт]. – URL: https://scikit-learn.org/stable/modules/model_evaluation.html (дата обращения: 16.05.2026). – Текст: электронный.

[5] Permutation feature importance : руководство пользователя scikit-learn : [сайт]. – URL: https://scikit-learn.org/stable/modules/permutation_importance.html (дата обращения: 16.05.2026). – Текст: электронный.